


Robotik

Prof. Dr. Thomas Wiemann - FB AI - Robotik



Hochschule Fulda
University of Applied Sciences





Gliederung



Sensordatenverarbeitung

1. Allgemeines
2. Globale Positionsbestimmung
3. Bewegungsmessung /
Odometrie
4. **Entfernungsmessung**
5. Navigation
6. Ausblick



Triangulation (1)

- ▶ Triangulation: Messung der Distanz durch Messung des Winkels eines Echos
- ▶ Funktioniert gut mit fokussierten Signalquellen (Laserlicht)



nach Strahlensatz:

$$\frac{D}{f} = \frac{L}{x} \Leftrightarrow D = f \frac{L}{x}$$

L : **Parallaxe**
 f : **Brennweite**




Triangulation (2)

- Messprinzip bedingt zwei Grenzen des Messbereichs


Blindbereich

f, L müssten klein gewählt sein




Fernauflösung



f, L müssten groß gewählt sein



- Beispiel Infrarotsensor:
 - in kurzen Messbereichen sehr präzise
 - billig (ab ~15 €)
 - kompakt

Fig.6 Analog Output Voltage vs.Distance
Reflective Object







- Kantensprünge sind aufgrund der Strahlaufweitung problematisch



Phasendifferenzmessung



- ▶ Phasendifferenzmessung (modulierter) Trägerfrequenzen
- ▶ Wird von verschiedenen Time-of-Flight Kamera eingesetzt
- ▶ Hohe Datenraten (bis zu 500.000 Punkte / s)
- ▶ Nachteil Mehrdeutigkeiten ($\lambda/2$)
- ▶ Technisch machbar ca. 200 m
- ▶ Relativ niedrige Kosten





Laufzeitmessung

- ▶ Lichtgeschwindigkeit (Laserstrahl) ca. 0,3m/ns
- ▶ Schallgeschwindigkeit in Luft ca. 0,3m/ms
- ▶ Laserstrahl stark gebündelt
- ▶ Schallsignal „läuft auseinander“
 - ▶ beides hat Vor- und Nachteile!
- ▶ Schall eher im Nahbereich (bis ca. 1m);
 - ▶ Laser eher im mittleren Bereich (bis ca. 20m oder weiter)
- ▶ beide brauchen homogenes Medium
 - ▶ kein Nebel, Regen, Wind etc.
- ▶ Aufgrund des Prinzips Probleme mit
 - ▶ Totalreflexion, „Echo“ (beide)
 - ▶ „matten“ Oberflächen (beide)
 - ▶ „durchsichtigen“ Oberflächen (Glas etc.: Laser)
- ▶ Beides robuste, wohl erprobte Technologien




"Attention is All you Need," Neural Information Processing Systems



Ultraschallentfernungsmessung

- Gemessener Abstand = Abstand zum nächsten Reflexionspunkt innerhalb der Schallkeule



Öffnungswinkel ca. 20°

Ultraschall

Eignet sich gut zur Kollisionsvermeidung,
aber schlecht zur Aufnahme der
Umgebungsgeometrie





Laserscanner (Laufzeitmessung)

Vakuumlichtgeschwindigkeit $c = 299.702.458 \frac{m}{s}$

Also: $d = 299.702.458 \frac{m}{s} \cdot t$

d: Distanz in m
t: gemessene Laufzeit in s



Technische Anforderungen:

$c \approx 0,3\text{mm/ps}$ Bei Auflösung von 10mm: Präzision der Laufzeitmessung im Bereich pico-Sek. (10^{-12}s) erforderlich!





- ▶ **Öffnungswinkel α**
 - SICK LMS-200: 180°
 - LMS-100 u. TiM: 270°
 - Hokuyo URG-04LX: 240°
- ▶ **Winkelauflösung δ**
 - SICK LMS-200: 0,25°, 0,5°, 1° einstellbar
 - LMS-100: 0,25°, 0,5°
 - TiM: 1°
 - Hokuyo ~0.352°
- ▶ Output pro Scan: $\alpha/\delta + 1$ Paare $\langle \text{Winkel}, \text{Entfernung} \rangle$
- ▶ Eventuell (je nach Scanner) **Remissionswert**, **Mehrfachecho** erhältlich






Darstellung der Messdaten






Flurfahrt aus Sicht eines Roboters





Remissionswerte beim LMS 200



Black construction paper

10 %

Gray cardboard

20 %

Wood (pine, raw, dirty)

40 %

White paper

80 %


Steel (high-gloss)

140...200 %




Spotdurchmesser

- Auch Laserstrahlen sind nicht perfekt fokussiert





- ▶ Erwarteter Scanwert ist Addition aus:
 - „echtem“ Wert (gaußverteilt mit statist. Fehler s nach Datenblatt)
 - Grundrauschen über Messbereich (gleichverteilt)
 - dynamische Störungen vor echtem Wert (exponentialverteilt)
 - Messartefakte in max. range
 - Messartefakte durch Absorption, Reflexion



Meistens trotzdem approximiert durch Gaußverteilung



- ▶ Solange für Sequenz von Messwerten $a_i, \dots, a_j$ gilt: $\|a_i, a_j\| \leq \delta(i - j)$, ersetze $a_i, \dots, a_j$ durch

$$\frac{1}{j - i + 1} \sum_{k=i}^j a_k$$




Ersetze eine Schar nah aneinander liegender Messwerte durch ihren Mittelwert

- ▶ Voraussetzungen:
 - ▶ Messwerte geordnet (wie beim Laserscanner)
 - ▶ Metrik $\|\cdot, \cdot\|$ auf Messwerten
 - ▶ δ -Schranke (hängt möglicherweise von der Punktzahl ab)



Eigenschaften des Reduktionsfilters

► Beispiel:



- Falls N Messwerte geordnet vorliegen (Laserscanner!), Zeitkomplexität $\mathcal{O}(n)$
- Reduktionsfilter glättet als Nebeneffekt Messwertrauschen
- Ausreißer bleiben erhalten



Medianfilter

- ▶ Ersetze jeden Messwert durch den Median seiner Umgebung aus k Werten:
- ▶ Ersetze für alle i den Wert a_i durch

$$\text{Median}\left(a_{i-\lfloor k/2 \rfloor}, \dots, a_i, \dots, a_{i+\lfloor k/2 \rfloor}\right)$$

- ▶ Voraussetzungen:
 - ▶ N Messwerte
 - ▶ Metrik auf Messwerten (z.B. Euklidische Distanz)

Eigenschaften:



Für N Messwerte **Zeitkomplexität** $\mathcal{O}(N \cdot k \cdot \log k)$ wegen der Sortierung nach Distanz für die Medianberechnung.

Medianfilter verfälscht “echte” Sprünge in $< k$ Messwerten.





Beispiel Medianfilter

Originalscan



polar

Scan nach Medianfilterung



karthesisch



- ▶ Sind ein Mega-Thema für mobile Robotik.
- ▶ Die Standardfälle sind inzwischen gut verstanden),
- ▶ Daher viele Lösungsansätze!
- ▶ Beispiel, die im Buch zu finden sind:
 1. Lokalisierung an Scanpunkten (Punktkarte vs. Scanner)
 2. Lokalisierung an Linien (Linienkarte vs. Scanner) – diesmal nicht :-(
 3. Lokalisierung an (visuellen) Merkmalen – diesmal nicht :-/
 4. Unimodale probabilistische Lokalisierung (Kalman-L.) - yeah!
 5. Probabilistische Lokalisierung in Rasterkarten (Markow-L.) - yesss!
 6. wie 5, aber mit Sampling (MCL) - wowie :-D

Nummern 1.-4. beruhen auf inkrementeller Lokalisierung!



- ▶ Gegeben:
 - Karte aus Messpunkten
 - a priori Poseschätzung (z.B. durch (Gyr-)Odometrie oder GPS)
 - aktueller Laserscan
- ▶ Finde:
 - Pose in der Karte
- ▶ Bemerkung:
 - Ist die „Karte“ der vorige Laserscan, bekommt man hier ein Verfahren zur inkrementellen Lokalisierung!

Registrierung:

Gegeben: Modell-Punktwolke $\mathcal{M}$ und Daten-Punktwolke $\mathcal{D}$ (z.B. Punkt-Karte und aktueller Laserscan). Gesucht wird die Transformation (Translation & Rotation) von $\mathcal{D}$, sodass sie $\mathcal{M}$ optimal passend überlagert.




Positionsschätzung durch 2D Scanmatching

► Beispiel:

- Nach Poseänderung von ca. $[4, 1, -10^\circ]^T$ (Odometrie-Schätzung) finden sich im Scan zwei Punkte P'_1 und P'_2 (lokales System!).
- Gäbe es aus voriger Pose im Scan die selben Raumpunkte als P_1, P_2 , so könnte die Poseschätzung verfeinert werden!

► Vorgehen:

- Finde/rate korrespondierende Raumpunkte unter den Scanpunkten beider Scans
- Errechne Poseänderung aus Translation & Rotation der entsprechenden Scanpunkte





Scanmatching als Fehlergradientenabstieg

- ▶ Wenn
 - wahre N Paare (P_i, P'_i) korrespondierender Raumpunkte als Scanpunkte vorkommen und alle P_i, P'_i jeweils präzise korrekte Scanwerte haben
- ▶ Dann
 - charakterisiert das Minimum (= Nullstelle) der folgenden Fehlerfunktion die Poseänderung um $(t_x, t_t, \theta)^T$ präzise:

$$E(\theta, T) = \sum_{i=1}^N \text{dist}(P_i, \text{transf}(P'_i)) = \sum_{i=1}^N \|P_i - (R_\theta \cdot P'_i + T)\|^2$$

(Transformation=Rotation+Translation im Referenz-Koord.-System!)

Aber:

Beide Voraussetzungen praktisch nicht erfüllbar!

- ▢ Minimum $\neq 0$ von E schätzt Poseänderung
- ▢ Und wie findet man das/ein Minimum?



Fehlerminimierung für (θ, T)

- Das Problem ist geschlossen lösbar!

Lemma (Lu / Milios):

Die folgende Transformation $(t_x, t_z, \theta)^T$ minimiert die Fehlerfunktion $E(\theta, T)$ bei gegebenen Punktkorrespondenzen

$$\theta = \arctan \frac{S_{zx'} - S_{xz'}}{S_{xx'} + S_{zz'}}$$

$$t_x = c_x - (c'_x \cos \theta - c'_z \sin \theta)$$

$$t_z = c_z - (c'_x \sin \theta + c'_z \cos \theta)$$

Dabei sind:

$$\begin{aligned} c_x &= \frac{1}{N} \sum_i p_{x,i} & S_{xx'} &= \sum_i (p_{x,i} - c_x)(p'_{x,i} - c'_x) \\ c'_x &= \frac{1}{N} \sum_i p'_{x,i} & S_{xz'} &= \sum_i (p_{x,i} - c_x)(p'_{z,i} - c'_z) \\ c_z &= \frac{1}{N} \sum_i p_{z,i} & S_{zx'} &= \sum_i (p_{z,i} - c_z)(p'_{x,i} - c'_x) \\ c'_z &= \frac{1}{N} \sum_i p'_{z,i} & S_{zz'} &= \sum_i (p_{z,i} - c_z)(p'_{z,i} - c'_z) \end{aligned}$$




Beweisidee des Lu / Milios-Lemmas

- ▶ Im Detail s. Buch Kap. 5.3 (S. 180ff). Grundidee:
- ▶ Trenne Rotations- und Translationskomponente R_θ , T durch Bezug beider Scans auf ihre Schwerpunkte c , c'
- ▶ Ermittle θ zuerst als optimal passende Rotation je um c , c'
 - daher stammen die Korrelationen S
- ▶ Die Translation ist dann einfach die Differenz zwischen Schwerpunkt c des Modellscans und um θ rotiertem Schwerpunkt c' des Datenscans:


$$\begin{pmatrix} t_x \\ t_z \end{pmatrix} = \begin{pmatrix} c_x \\ c_z \end{pmatrix} - \mathbf{R}_\Theta \begin{pmatrix} c'_x \\ c'_z \end{pmatrix}$$




Tafelbeispiel



Initiale Anordnung



Minimierung des Rotationsunterschieds durch
Drehung um den Schwerpunkt



Translation auf den Schwerpunkt der Referenz



Nachrechnen der Minimierung (1)

Beweis. Seien $\bar{\mathbf{p}}_i = \mathbf{p}_i - \mathbf{c}$ und $\bar{\mathbf{p}}'_i = \mathbf{p}'_i - \mathbf{c}'$ die Modell- bzw. Datenpunkte, die um die jeweiligen Schwerpunkte der Mengen verschoben worden sind, also

$$\mathbf{c} = \begin{pmatrix} c_x \\ c_z \end{pmatrix} = \frac{1}{N} \sum_{i=1}^N \mathbf{p}_i \quad \mathbf{c}' = \begin{pmatrix} c'_x \\ c'_z \end{pmatrix} = \frac{1}{N} \sum_{i=1}^N \mathbf{p}'_i . \quad (5.15)$$

Formel (5.12) lässt sich damit umformen zu

$$\begin{aligned} E(\theta, \mathbf{t}) &= \sum_{i=1}^N \|\mathbf{p}_i - (\mathbf{R}_\theta \mathbf{p}'_i + \mathbf{t})\|^2 \\ &= \sum_{i=1}^N \|\bar{\mathbf{p}}_i + \mathbf{c} - (\mathbf{R}_\theta (\bar{\mathbf{p}}'_i + \mathbf{c}') + \mathbf{t})\|^2 \\ &= \sum_{i=1}^N \|\bar{\mathbf{p}}_i - \mathbf{R}_\theta \bar{\mathbf{p}}'_i - \underbrace{(\mathbf{t} - \mathbf{c} + \mathbf{R}_\theta \mathbf{c}')}_{=: \tilde{\mathbf{t}}}\|^2 \end{aligned} \quad (5.16)$$



Nachrechnen der Minimierung (2)

$$\leq \underbrace{\sum_{i=1}^N \|\bar{\mathbf{p}}_i - \mathbf{R}_\theta \bar{\mathbf{p}}'_i\|^2}_{(a)} - \underbrace{2\tilde{t} \sum_{i=1}^N \|\bar{\mathbf{p}}_i - \mathbf{R}_\theta \bar{\mathbf{p}}'_i\|}_{(b)} + \underbrace{\sum_{i=1}^N \|\tilde{t}\|^2}_{(c)} .$$

Der zweite Term (b) ist Null, da gilt:

$$\begin{aligned} \sum_{i=1}^N (\bar{\mathbf{p}}_i - \mathbf{R}_\theta \bar{\mathbf{p}}'_i) &= \sum_{i=1}^N (\mathbf{p}_i - \mathbf{c} - \mathbf{R}_\theta \mathbf{p}'_i + \mathbf{R}_\theta \mathbf{c}') & (5.17) \\ &= \sum_{i=1}^N \left(\mathbf{p}_i - \frac{1}{N} \sum_{j=1}^N \mathbf{p}_j - \mathbf{R}_\theta \mathbf{p}'_i + \frac{1}{N} \sum_{j=1}^N \mathbf{R}_\theta \mathbf{p}'_j \right) \\ &= \sum_{i=1}^N \mathbf{p}_i - \underbrace{\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N \mathbf{p}_j}_{= \sum_{i=1}^N \mathbf{p}_i} - \sum_{i=1}^N \mathbf{R}_\theta \mathbf{p}'_i + \underbrace{\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N \mathbf{R}_\theta \mathbf{p}'_j}_{= \sum_{i=1}^N \mathbf{R}_\theta \mathbf{p}'_i} \\ &= 0 . \end{aligned}$$



Nachrechnen der Minimierung (3)

Der dritte Term (c) wird minimal bei

$$t = c - R_{\theta} c' . \quad (5.18)$$

Demnach reicht es zur Minimierung der ursprünglichen Fehlerfunktion aus, die Funktion $\bar{E}(\theta)$ zu minimieren, die nun nicht mehr von der Translation abhängt:

$$\bar{E}(\theta) = \sum_{i=1}^N \left\| \bar{p}_i - R_{\theta} \bar{p}'_i \right\|^2 , \quad (5.19)$$

die sich weiter umformen lässt zu:

$$= \sum_{i=1}^N \left\| \bar{p}_i \right\|^2 - 2 \underbrace{\sum_{i=1}^N \bar{p}_i \cdot R_{\theta} \bar{p}'_i}_{\text{Rotationsterm}} + \underbrace{\sum_{i=1}^N \left\| R_{\theta} \bar{p}'_i \right\|^2}_{= \sum_{i=1}^N \left\| \bar{p}_i \right\|^2} . \quad (5.20)$$



Nachrechnen der Minimierung (4)


$$\begin{aligned}\frac{\partial}{\partial \theta} \bar{E}(\theta) &= \frac{\partial}{\partial \theta} \sum_{i=1}^N (\bar{p}_{x,i}, \bar{p}_{z,i}) \cdot \begin{pmatrix} \bar{p}'_{x,i} \cos \theta - \bar{p}'_{z,i} \sin \theta \\ \bar{p}'_{x,i} \sin \theta + \bar{p}'_{z,i} \cos \theta \end{pmatrix} \\ &= \sum_{i=1}^N (-\sin \theta (\bar{p}_{x,i} \bar{p}'_{x,i} + \bar{p}_{z,i} \bar{p}'_{z,i}) - \cos \theta (\bar{p}_{x,i} \bar{p}'_{z,i} - \bar{p}_{z,i} \bar{p}'_{x,i})) \\ &\stackrel{!}{=} 0 .\end{aligned}\tag{5.21}$$

Nach θ aufgelöst ergibt sich, wegen $\tan \theta = \sin \theta / \cos \theta$, die Lösung:

$$\theta = \arctan \left(\frac{\sum_{i=1}^N (\bar{p}_{z,i} \bar{p}'_{x,i} - \bar{p}_{x,i} \bar{p}'_{z,i})}{\sum_{i=1}^N (\bar{p}_{x,i} \bar{p}'_{x,i} + \bar{p}_{z,i} \bar{p}'_{z,i})} \right) ,\tag{5.22}$$



Beispiel



$$P_1 = (x_1, z_1) = (5, 4)$$

$$P_2 = (x_2, z_2) = (6, 2)$$

$$P_1' = (x_1', z_1') = (1.5, 2.7)$$

$$P_2' = (x_2', z_2') = (2, 0.5)$$

$$c_x = \frac{1}{2}(5 + 6) = 5.5$$

$$c_z = 3.0$$

$$c_x' = 1.75$$

$$c_z' = 1.6$$

$$S_{xx'} = (5 - 5.5)(1.5 - 1.75) + (6 - 5.5)(2 - 1.75) = 0.25$$

$$S_{zz'} = (4 - 3)(2.7 - 1.6) + (2 - 3)(0.5 - 1.6) = 2.2$$

$$S_{xz'} = (5 - 5.5)(2.7 - 1.6) + (6 - 5.5)(0.5 - 1.6) = -1.1$$

$$S_{zx'} = (4 - 3)(1.5 - 1.75) + (2 - 3)(2 - 1.75) = -0.5$$

$$\theta = \arctan \frac{S_{zx'} - S_{xz'}}{S_{xx'} + S_{zz'}} = \arctan \frac{0.6}{2.45} = 13,7608^\circ$$

$$t_x = c_x - (c_x' \cos \theta - c_z' \sin \theta) = 5.5 - (1.6998 - 0.3806) = 4.1808$$

$$t_z = c_z - (c_x' \sin \theta + c_z' \cos \theta) = 3 - (0.4163 + 1.5541) = 1.0396$$

$$\Delta \theta_{robot} = -3.76^\circ$$

$$\theta_{robot} = -13.76^\circ$$

$$\Delta T = (0.18, 0.04)$$

Schätzung hier nicht gebraucht. Aber...




Grundidee 2D-Scanmatching-Algorithmus

1. Nimm geschätzten Roboterposeversatz (θ, T) (mit Odometrie etc.) als **Start-Schätzung** des Scanposeversatzes
2. **Finde auf Basis der aktuellen Schätzung** des Scanposeversatzes (θ, T) **korrespondierende Punkte** in Modellscan und Datenscan
3. **Aktualisiere** (θ, T) durch Minimierung von $E(\theta, T)$ wie gehabt; bestimme dabei $(\Delta\theta, \Delta T)$ (Änderung von (θ, T) gegenüber vorher)
4. Ist $(\Delta\theta, \Delta T)$ **kleiner als vorgegebene Schranke**, **terminiere** mit aktuellem (θ, T) als ermitteltem Scanposeversatz. Ansonsten gehe zu 2 mit (θ, T) als aktueller Schätzung

Finden / Raten der „richtigen“ Korrespondenzen spart Laufzeit. Neuberechnen von Korrespondenzen in #2 kostet Laufzeit!




Auffinden der Punktkorrespondenzen




Gegeben „Modell“ (z.B. Referenz-Scan, kontinuierliche Kurve), welche Scanpunkte P'_i („Datenpunkte“) entsprechen Modell-Punkten P_i ? Wieviele / welche haben überhaupt eine Entsprechung? Und wenn –


- **Beispiel:** Messpunkte P'_i nach Schätzung der Poseänderung überlagert einer Modellmenge
 - Abstände minimieren?
 - Überdeckung maximieren?
 - (θ, T) minimieren?
 - Sichtbarkeit berücksichtigen?



Erste Iteration mit beschränktem
Suchradius ϵ



Durch Transformation entstehen
neue Korrespondenzen




Terminiere wenn
Delta der Transformationen
< Schranke



- ▶ Geh die Punkte (ggf. gefiltert) der Datenmenge durch
- ▶ Wenn für Datenpunkt P_i' in einer ε -Umgebung mindestens 1 Modellpunkt liegt, dann nimm den nächsten Modellpunkt dieser Umgebung als korrespondierenden Punkt. Definiere dabei Nähe als Euklidischen Abstand.
- ▶ Gibt es innerhalb der ε -Umgebung keinen Modellpunkt, hat P_i' keinen korrespondierenden
 - Grundlage des Algorithmus ICP (Iterative Closest Points, Besl/McKay, 1992) (z.T. Iterative Corresponding Points)
 - Analytisch: Konvergiert (gemeinsam mit Fehlergradientenabstieg) garantiert auf lokales Minimum von $E(\theta, T)$
 - Empirisch: Kompensiert Translationsfehler gut, wenn Rotationsfehler gering



Beispiel Korrespondenzen





2D-Scanmatching mit ICP


Eingabe : Punktmenge M , Scan D .

Ausgabe: Transformation $\mathbf{T} = (t_x, t_z, \theta)^T$, die D mit M registriert.

- 1: **if** Initiale Poseschätzung existiert **then**
 - 2: Setze $\mathbf{T}$ gleich dem geschätzten Poseversatz
 - 3: Transformiere D um $\mathbf{T}$
 - 4: **else**
 - 5: $\mathbf{T} = (t_x, t_z, \theta)^T = (0, 0, 0)^T$
 - 6: **end if**
 - 7: **repeat**
 - 8: Bestimme die Paarungen korrespondierender Punkte (z.B. mittels ICP-Regel)
 - 9: Berechne $\Delta\mathbf{T}$ durch Minimierung der Fehlerfunktion E wie in Folie 186 (Lu/Milios)
 - 10: $\mathbf{T} = \mathbf{T} + \begin{pmatrix} \cos \theta & -\sin \theta & 0 \\ \sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{pmatrix} \Delta\mathbf{T}$ *// Aktualisierung der Transformation*
 - 11: Transformiere D mit $\Delta\mathbf{T}$
 - 12: **until** Transformations-Inkrement $\Delta\mathbf{T}$ ist betragsmäßig unter einer Grenze.
 - 13: **return** $\mathbf{T}$
-




Beispiel: Scanmatching mit ICP







Beispiel: Scanmatching mit ICP



<https://www.youtube.com/watch?v=2-ru1r9uu9M>



Beispiel







ICP nutzt Punktkorrespondenzen $w_{i,j}$ in 2 Scans (nach Nähe)

Sei M (Modellscan), D (Datenscan) Scans mit Punkten (3D!) $\mathbf{m}_i, \mathbf{d}_j$. Finde $\mathbf{R}, \mathbf{t}$ (hier in 6D!), sodass $E(\mathbf{R}, \mathbf{t})$ minimal wird:

$$E(\mathbf{R}, \mathbf{t}) = \sum_{i=1}^{|M|} \sum_{j=1}^{|D|} w_{i,j} \left\| \mathbf{m}_i - (\mathbf{R} \mathbf{d}_j + \mathbf{t}) \right\|^2$$

► Tricks zur Beschleunigung

1. Datenreduktion
2. Berechnung von Rotation & Translation in geschlossener Form
3. k D-Bäume für Nachbarpunktsuche



2D-Rendering: Original + Bild mit reduzierten (+größer gemalten) Punkten



Fazit Sensorik / Bewegungsschätzung

Sensor	Lokalisierung	Kosten	Aufwand	Präzision
GPS	Global	Gering	Gering	Gering bis sehr gut, dann aber hohe Kosten, nur außen
Odometrie	Inkrementell	Praktisch Null	Gering	Gering
Gyroskop	Inkrementell	Gering	Gering	Gering bis sehr gut, vor allem bei Rotationen
Beacons	Global	Gering bis Hoch	Sehr hoch	Hoch bis sehr hoch (bei entsprechender Technik)
Laserscanner	Inkrementell	Mittel	Mittel	Hoch in Feature-reichen Umgebungen, sonst gering

Es macht Sinn, Informationen aus verschiedenen Sensoren zu kombinieren. Dazu benötigen wir einen allgemeineren Ansatz als die vorgestellten Speziallösungen. **Motto: von der Gyrodometrie zum Kalman-Filter**

Landmarken, die von den Sensoren erkannt werden, sollten in eine Repräsentation eingetragen werden, die dem Roboter die Lokalisierung erleichtert. **Vor allem brauchen wir einen Ansatz zur globalen Lokalisierung**, wenn der Roboter beim inkrementellen Schätzen Fehler macht.