


Robotik

Prof. Dr. Thomas Wiemann - FB AI - Robotik



Hochschule Fulda
University of Applied Sciences





- ▶ Betreuung eines Exponats in der KI-Welt auf dem Hessentag
- ▶ EDAG City Bot
- ▶ 3D-Pfadplanung und Navigation
- ▶ Umfang der Tätigkeit flexibel
- ▶ Bei Interesse: E-Mail an mich



EDAG City Bot





Gliederung

1. Einleitung
2. Robot Operating System
- 3. Lokalisierung**
4. Mapping
5. Navigation
6. Ausblick



Gliederung

Lokalisierung

1. **Grundlagen**
2. Bayes- und Kalmanfilter
3. Inkrementelle Lokalisierung
4. Lokalisierung in Karten
5. Navigation
6. Ausblick



Ergebnisraum Ω : Mögliche Ergebnisse eines
Zufallsexperiments

z.B.: {„1“, „2“, „3“, „4“, „5“, „6“} beim Würfeln
{[„1“, *sonnig*], [„1“, *regnet*], [„2“, *sonnig*], ..., [„6“, *regnet*]}

Ereignis:

Teilmenge v. Ω . z.B.: {„2“, „4“, „6“} beim Würfeln („gerade“)

Elementarereignis:

$\omega \in \Omega$. (eigentlich: einelementiges Ereignis) z.B.: [„1“, *sonnig*]

Zufallsvariable: Funktion von Elementarereignissen $\omega \in \Omega$ in
einen Wertebereich $\mathcal{D}$. (Notation: beginnt mit Großbuchstabe)

$\mathcal{D} = \{\text{true}, \text{false}\}$: **Boolesche** Zufallsvariable, z.B.: *Zahnloch*

$\mathcal{D}$ diskret: **Diskrete** ZV, z.B.: *Augenzahl* (auf einem Würfel)

$\mathcal{D}$ stetig (hier: $\mathbb{R}$): **kontinuierliche** ZV, z.B.: *Position* (Roboter im 2D)




Wdh.: Wahrscheinlichkeitsraum

Wahrscheinlichkeitsraum (Ω, P) , $\Omega \neq \emptyset$: P ist eine so auf Ereignissen aus Ω definierte reellwertige Funktion („Wahrscheinlichkeit“), dass die **Kolmogorow-Axiome** gelten:

1. $0 \leq P(e) \leq 1$ für alle $e \subseteq \Omega$
2. $P(\Omega) = 1$
3. Für $d, e \subseteq \Omega$ gilt: $P(d \cup e) = P(d) + P(e) - P(d \cap e)$

z.B.: $P(\text{„gerade“}) = P(\text{„2“}) + P(\text{„4“}) + P(\text{„6“}) = 1/6 + 1/6 + 1/6 = 1/2$

(W'raum präziser (Ω, Σ, P) mit Ereignisraum Σ – hier verkürzt dargestellt)



Ereign. a, b sind **unabhängig** auf (Ω, P) , gdw:

$$P(a \cap b) = P(a) \cdot P(b)$$



P induziert Funktionen auf den Zufallsvariablen über (Ω, P) :

Wahrscheinlichkeitsverteilung P einer diskreten Zufallsvariablen X : Liste aus W'keiten der möglichen Werte für X , wobei $\sum_{x \in \text{Range}(X) \subseteq \Omega} P(x) = 1$

z.B.: $P(\text{Augenzahl}) = \langle P(„1“), \dots, P(„6“) \rangle = \langle 1/6, 1/6, 1/6, 1/6, 1/6, 1/6 \rangle$

Notation: $P(\text{Augenzahl} = „1“) = 1/6$


Wahrscheinlichkeitsdichte P einer kontinuierlichen Zufallsvariablen X : Fkt. vom Typ $\text{Range}(X) \rightarrow [0,1]$, wobei

und $P(a \leq x \leq b) = \int_a^b P(x) dx$ $\int_{x \in \text{Range}(X) \subseteq \Omega} P(x) dx = 1$
z.B.: ...



Beispiel für Wahrscheinlichkeitsdichte

$\mathbf{P(Temperatur) = U[18,26](x) =}$
Gleichverteilung auf $[18,26]$



$$\int_{-\infty}^{\infty} U[18,26](x)dx = \int_{18}^{26} U[18,26](x)dx = 1$$

$$\mathbf{P(20 \leq Temperatur \leq 22) = \int_{20}^{22} U[18,26](x)dx = 0,25 = P(...)}$$

$$P(20,5) = 0$$


$$\mathbf{P(Temperatur=20,5) = \lim_{dx \rightarrow 0} P(20,5 \leq X \leq 20,5+dx)/dx = 0,125/^{\circ}\text{C}}$$



Kausalität und Korrelation



DRY, HOT AND SUNNY
SUMMER WEATHER





Unbedingte Wahrscheinlichkeiten

W'keit P „an sich“, ohne weitere Information:

Unbedingte Wahrscheinlichkeit (**a priori** W'keit)

z.B.: $P(\text{regnet}) = 0,3$

Verteilung für unbedingte W'keiten wie beschrieben

z.B.: $P(\text{OSWetter}) = \langle P(\text{sonnig}), P(\text{wolkig}), P(\text{regnet}), P(\text{frostig}) \rangle$
 $= \langle 0,25, 0,4, 0,3, 0,05 \rangle$

Gemeinsame Verteilung von n ZVen entspricht n -dim. Tabelle:

Notation: $P(ZV_1 \cap ZV_2)$
 oder $P(ZV_1, ZV_2)$

Beispiel:

$P(\text{OSWetter}, \text{Zahnloch})$

$\text{OSWetter} =$ $\text{Zahnloch} =$	<i>sonnig</i>	<i>wolkig</i>	<i>regnet</i>	<i>frostig</i>
<i>false</i>	0,225	0,36	0,27	0,045
<i>true</i>	0,025	0,04	0,03	0,005

Vollständige gem. Verteilg.: W'keit aller Elementarereignisse
 (hat $O(m^n)$ Einzelw'keiten für n ZVen mit max. m Werten)



W'keit P bei gegebener Information:

Bedingte Wahrscheinlichkeit (**a posteriori** W'keit)

z.B.: $P(\text{regnet} \mid \text{luftdruck_hoch}) = 0,1$

Definiert (falls $P(b) > 0$) als $P(a \mid b) := \frac{P(a \cap b)}{P(b)}$
($P(a \mid b) = 0$, falls $P(b) = 0$)

... oder als („Produktregel“): $P(a \cap b) = P(a \mid b)P(b) = P(b \mid a)P(a)$

z.B.: $P(\text{sonnig} \mid \neg \text{zahnloch}) = 0,225 / 0,9 = 0,25$

entspricht $P(\text{sonnig})$, weil unabhängig!

Entsprechend für W'venteilungen:

$$\mathbf{P}(\text{OSWetter}, \text{Zahnloch}) = \mathbf{P}(\text{OSWetter} \mid \text{Zahnloch}) \mathbf{P}(\text{Zahnloch})$$



Bedingte Unabhängigkeit

Zwei Ereignisse a, b sind **bedingt unabhängig**, gegeben c ,
gdw.:

$$P(a, b \mid c) = P(a \mid c) P(b \mid c)$$

Zwei Zufallsvariable A, B sind **bedingt unabhängig**, geg. C ,
gdw.:

$$\mathbf{P}(A, B \mid C) = \mathbf{P}(A \mid C) \mathbf{P}(B \mid C)$$

Damit äquivalent sind die Formulierungen

$$\mathbf{P}(A \mid B, C) = \mathbf{P}(A \mid C) \text{ und } \mathbf{P}(B \mid A, C) = \mathbf{P}(B \mid C)$$

↪ **kleinere Verteilungen ohne volle Unabhängigkeit!!**



Die Bayes'sche Regel

Erinnerung Produktregel: $P(a \cap b) = P(a|b)P(b) = P(b|a)P(a)$

„Satz“ von Bayes

$$P(b | a) = \frac{P(a | b)P(b)}{P(a)} = \alpha \cdot P(a | b)P(b)$$

... oder für Verteilungen:

$$\mathbf{P}(Y | X) = \frac{\mathbf{P}(X | Y)\mathbf{P}(Y)}{\mathbf{P}(X)} = \alpha \cdot \mathbf{P}(X | Y)\mathbf{P}(Y)$$



Anwendung: Diagnoseregeln

$$P(\text{ursache} \mid \text{wirkung}) = \frac{P(\text{wirkung} \mid \text{ursache}) \cdot P(\text{ursache})}{P(\text{wirkung})}$$

Oft sind kausale Zusammenhänge besser bekannt
als diagnostische

Verwendung in der Robotik

$$\mathbf{P}(\text{Zustand} \mid \text{Messung}) = \frac{\mathbf{P}(\text{Messung} \mid \text{Zustand}) \cdot \mathbf{P}(\text{Zustand})}{\mathbf{P}(\text{Messung})}$$

Beispiel

$$P(\text{Briefbox} = \text{voll} \mid \text{Fahne} = \text{hoch}) = \frac{P(\text{Fahne} = \text{hoch} \mid \text{Briefbox} = \text{voll}) \cdot P(\text{Briefbox} = \text{voll})}{P(\text{Fahne} = \text{hoch})}$$



Erwartungswert

(e. numerischen diskreten ZV)

$$E(X) = \sum_i x_i \cdot P(X = x_i)$$

- repräsentiert „erwartetes“ Ergebnis e. zufälligen Messung
- i.a. nicht dasselbe wie Mittelwert!

Beispiele

- Würfel: $E(\text{Augenzahl}) = 1/6 \cdot (1+2+3+4+5+6) = 3,5$
- Münze: $E(\text{Münzwurf}) = 1/2 \cdot (0+1) = 0,5$
- bei gleichverteilter ZV ist E-Wert gleich Mittelwert



(Ko)Varianz, Korrelation

Varianz ist „Streuung der Abweichung vom Erwartungswert“:

$$V(X) = \sigma_X^2 := E\left((X - E(X))^2\right)$$

Kovarianz ist „Zusammenhang“ zweier ZV:

$$\sigma_{XY} = E(XY) - E(X)E(Y) = E\left((X - E(X))(Y - E(Y))\right)$$

- positiv bei gleichsinnigem Zusammenhang
- negativ bei gegensinnigem
- 0 bei fehlendem Zusammenhang
($\neq$ Unabhängigkeit! Aber: Wenn unabhängig, dann Kovarianz = 0)

Korrelation ist auf $[-1,1]$ normierte Kovarianz

Eine **Kovarianzmatrix** Σ listet d. Kovarianzen aller Paare einer Menge v. ZV $X_1, \dots, X_n$.

(Symmetrisch, da $\sigma_{ik} = \sigma_{ki}$; ($\sigma_{ii} = \sigma_i^2$))

$$\begin{pmatrix} \sigma_{11} & \cdots & \sigma_{1n} \\ \vdots & \ddots & \vdots \\ \sigma_{n1} & \cdots & \sigma_{nn} \end{pmatrix}$$



Gaußverteilung


Gaußverteilung mit Mittelwert μ
und Standardabweichung σ :

$$P(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Standard-Normalverteilung ($\mu=0, \sigma=1$): $P(x) = e^{-x^2/2} / \sqrt{2\pi}$

$$\begin{aligned} P(\mu-\sigma < X \leq \mu+\sigma) &\approx 0.68 \\ P(\mu-2\sigma < X \leq \mu+2\sigma) &\approx 0.955 \\ P(\mu-3\sigma < X \leq \mu+3\sigma) &\approx 0.997 \end{aligned}$$

Standardabweichung σ ist
die Wurzel der Varianz





Multivariate Gaußverteilungen


$$P(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$$

... sind direkte Verallgemeinerungen eindimensionaler Gaußverteilungen auf n -dim. Vektor $\mathbf{x}$ für eine n -dim. Kovarianzmatrix Σ , wobei für Skalar x (also $n=1$) gilt: $\Sigma=\sigma^2$

$$P(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n \cdot \text{Det}(\Sigma)}} e^{-\frac{1}{2}((\mathbf{x}-\mu)^T \Sigma^{-1} (\mathbf{x}-\mu))}$$

(Nach Konstruktion:
 Σ invertierbar, $\text{Det}(\Sigma) \neq 0$!


Erinnerung: $\text{Det}(r)=r$





Totale Wahrscheinlichkeit

- Benötigt, wenn man nur die bedingte oder gemeinsame Wahrscheinlichkeit hat



<https://studyflix.de/statistik/satz-der-totalen-wahrscheinlichkeit-1111>

$$P(A) = P(A \cup B) + P(A \cup \bar{B})$$

$$P(A) = P(B) \cdot P(A | B) + P(\bar{B}) \cdot P(A | \bar{B})$$



Statistische Unabhängigkeit

- ▶ Löst “schärfer Hingucken” Unsicherheit auf?
- ▶ Extrembeispiel: Nutze die selbe Information mehrmals
 - ▶ Intuition sagt: “Das kann nichts bringen!”
 - ▶ Wahrscheinlichkeitstheorie sagt: “Stimmt!”

$$P(a|b,b) = P(a|b)P(b|b) = P(a|b)$$

Messungen müssen **statistisch unabhängig** sein:
 $P(a \cap b) = P(a) \cdot P(b)$ also $P(a|b)=P(a)$ und $P(b|a)=P(b)$

- ▶ Messungen „desselben“ an derselben Stelle sind abhängig
- ▶ Modelliere alle Messungen eines Zustands als eine Messung
- ▶ Auch konsekutive Messungen auf Robotern
- ▶ (z.B. bei Lokalisierung) sind statistisch meist nicht unabhängig
- ▶ Praktisch kümmert man sich meist nicht darum!



Gliederung

Lokalisierung

1. Grundlagen
- 2. Bayes- und Kalmanfilter**
3. Inkrementelle Lokalisierung
4. Lokalisierung in Karten
5. Navigation
6. Ausblick



Bayes-Filter - Motivation


- ▶ Angenommen, ein Roboter macht die Messung z
- ▶ Was ist $P(\text{open}, z)$?
- ▶ Kausales vs. diagnostisches schließen
- ▶ $P(\text{open} | z)$ ist diagnostisch
- ▶ $P(z | \text{open})$ ist kausal
- ▶ Die Bayes'sche Regel erlaubt es uns kausales Wissen zu nutzen:

Zählen!

$$P(\text{open} | z) = \frac{P(z | \text{open})P(\text{open})}{P(z)}$$

$$P(z) = P(z | \text{open}) \cdot P(\text{open}) + P(z | \neg \text{open}) \cdot P(\neg \text{open})$$

(Totale Wahrscheinlichkeit)





Bayes-Filter - Beispiel (1)

- Beispiel einer einfachen Messung

$$P(z | \text{open}) = 0.6 \qquad P(z | \neg \text{open}) = 0.3$$

$$P(\text{open}) = P(\neg \text{open}) = 0.5$$

$$P(\text{open} | z) = \frac{P(z | \text{open})P(\text{open})}{P(z | \text{open})P(\text{open}) + P(z | \neg \text{open})P(\neg \text{open})}$$

$$P(\text{open} | z) = \frac{0.6 \cdot 0.5}{0.6 \cdot 0.5 + 0.3 \cdot 0.5} = \frac{2}{3} = 0.67$$

- z erhöht die geschätzte Wahrscheinlichkeit, dass die Tür offen ist



Bayes-Filter - Beispiel (2)

► Zweite Messung:

$$P(z_2 | \text{open}) = 0.5 \qquad P(z_2 | \neg \text{open}) = 0.6$$

$$P(\text{open} | z_1) = 2/3 \quad \leftarrow \text{Ergebnis aus dem vorherigen Schritt}$$

$$P(\text{open} | z_1, z_2) = \frac{P(z_2 | \text{open})P(\text{open} | z_1)}{P(z_2 | \text{open})P(\text{open} | z_1) + P(z_2 | \neg \text{open})P(\neg \text{open})}$$

$$P(\text{open} | z_1, z_2) = \frac{\frac{1}{2} \cdot \frac{2}{3}}{\frac{1}{2} \cdot \frac{2}{3} + \frac{3}{5} \cdot \frac{1}{3}} = \frac{5}{8} = 0.625$$

► z_2 reduziert die Wahrscheinlichkeit, dass die Tür offen ist.



Bayes-Filter - Rekursives updaten

- ▶ Angenommen, unser Roboter führt eine weitere Messung durch
- ▶ Wie können wir diese Information berücksichtigen?
- ▶ Allgemein: Wie können wir $P(x | z_1 \dots z_n)$ berechnen?


$$P(x | z_1, \dots, z_n) = \frac{P(z_n | x, z_1, \dots, z_{n-1})P(x | z_1, \dots, z_{n-1})}{P(z_n | z_1, \dots, z_{n-1})}$$

- ▶ **Markov-Annahme:** z_n ist unabhängig von $z_1, \dots, z_{n-1}$ wenn wir x kennen.

$$\begin{aligned} P(x | z_1, \dots, z_n) &= \frac{P(z_n | x)P(x | z_1, \dots, z_{n-1})}{P(z_n | z_1, \dots, z_{n-1})} \\ &= \alpha P(z_n | x)P(x | z_1, \dots, z_{n-1}) \\ &= \alpha_n \prod_{i=1 \dots m} P(z_n | x_i)P(x_i | z_{1:n-1}) \end{aligned}$$



- ▶ In den meisten Fällen ist die Welt dynamisch
- ▶ Aktionen des Roboters oder von anderen Agenten
- ▶ Wie können wir solche Aktionen in unser Modell integrieren?
- ▶ Typische Aktionen:
 - ▶ Der Roboter dreht seine Räder
 - ▶ Der Roboter benutzt seinen Manipulator, um ein Objekt zu greifen
 - ▶ Pflanzen wachsen über die Zeit
- ▶ Aktionen haben nicht mit 100% Wahrscheinlichkeit das gewünschte Resultat
- ▶ Im Gegensatz zu Messungen erhöhen Aktionen im Allgemeinen die Unsicherheit
- ▶ Zur Modellierung fügen wir die Aktion u in den aktuellen Belief ein




$$P(x_t \mid u, x_{t-1})$$



Zustandsübergänge

- ▶ $P(x_t | u, x_{t-1})$ für $u = \text{"schlieÙe die Tür"}$



- ▶ Wenn die Tür offen ist, ist die Aktion in 90% aller Fälle erfolgreich
- ▶ Integration über die Ausgänge:

$$P(x_t | u) = \int P(x | u, x_{t-1}) P(x_{t-1}) dx_{t-1}$$

(kontinuierlich)

$$P(x_t | u) = \sum P(x | u, x_{t-1}) P(x_{t-1})$$

(diskret)




Bayes-Filter - Beispiel (3)

► Dritte Aktion: "Tür schließen"

$$\begin{aligned}P(\text{closed} | u) &= \sum P(\text{closed} | u, x')P(x') \\&= P(\text{closed} | u, \text{open})P(\text{open}) \\&\quad + P(\text{closed} | u, \text{closed})P(\text{closed}) \\&= \frac{9}{10} * \frac{5}{8} + \frac{1}{1} * \frac{3}{8} = \frac{15}{16}\end{aligned}$$

$$\begin{aligned}P(\text{open} | u) &= \sum P(\text{open} | u, x')P(x') \\&= P(\text{open} | u, \text{open})P(\text{open}) \\&\quad + P(\text{open} | u, \text{closed})P(\text{closed}) \\&= \frac{1}{10} * \frac{5}{8} + \frac{0}{1} * \frac{3}{8} = \frac{1}{16} \\&= 1 - P(\text{closed} | u)\end{aligned}$$



$$P(\text{open}) = \frac{5}{8}$$