



Gliederung

Lokalisierung

1. Grundlagen
- 2. Bayes- und Kalmanfilter**
3. Inkrementelle Lokalisierung
4. Lokalisierung in Karten
5. Navigation
6. Ausblick



Bayes-Filter - Motivation


- ▶ Angenommen, ein Roboter macht die Messung z
- ▶ Was ist $P(\text{open}, z)$?
- ▶ Kausales vs. diagnostisches schließen
- ▶ $P(\text{open} | z)$ ist diagnostisch
- ▶ $P(z | \text{open})$ ist kausal
- ▶ Die Bayes'sche Regel erlaubt es uns kausales Wissen zu nutzen:

Zählen!

$$P(\text{open} | z) = \frac{P(z | \text{open})P(\text{open})}{P(z)}$$

$$P(z) = P(z | \text{open}) \cdot P(\text{open}) + P(z | \neg \text{open}) \cdot P(\neg \text{open})$$

(Totale Wahrscheinlichkeit)





Bayes-Filter - Beispiel (1)

- Beispiel einer einfachen Messung

$$P(z | \text{open}) = 0.6 \qquad P(z | \neg \text{open}) = 0.3$$

$$P(\text{open}) = P(\neg \text{open}) = 0.5$$

$$P(\text{open} | z) = \frac{P(z | \text{open})P(\text{open})}{P(z | \text{open})P(\text{open}) + P(z | \neg \text{open})P(\neg \text{open})}$$

$$P(\text{open} | z) = \frac{0.6 \cdot 0.5}{0.6 \cdot 0.5 + 0.3 \cdot 0.5} = \frac{2}{3} = 0.67$$

- z erhöht die geschätzte Wahrscheinlichkeit, dass die Tür offen ist



Bayes-Filter - Beispiel (2)

► Zweite Messung:

$$P(z_2 | \text{open}) = 0.5 \qquad P(z_2 | \neg \text{open}) = 0.6$$

$$P(\text{open} | z_1) = 2/3 \quad \leftarrow \text{Ergebnis aus dem vorherigen Schritt}$$

$$P(\text{open} | z_1, z_2) = \frac{P(z_2 | \text{open})P(\text{open} | z_1)}{P(z_2 | \text{open})P(\text{open} | z_1) + P(z_2 | \neg \text{open})P(\neg \text{open})}$$

$$P(\text{open} | z_1, z_2) = \frac{\frac{1}{2} \cdot \frac{2}{3}}{\frac{1}{2} \cdot \frac{2}{3} + \frac{3}{5} \cdot \frac{1}{3}} = \frac{5}{8} = 0.625$$

► z_2 reduziert die Wahrscheinlichkeit, dass die Tür offen ist.



Bayes-Filter - Rekursives updaten

- ▶ Angenommen, unser Roboter führt eine weitere Messung durch
- ▶ Wie können wir diese Information berücksichtigen?
- ▶ Allgemein: Wie können wir $P(x | z_1 \dots z_n)$ berechnen?


$$P(x | z_1, \dots, z_n) = \frac{P(z_n | x, z_1, \dots, z_{n-1})P(x | z_1, \dots, z_{n-1})}{P(z_n | z_1, \dots, z_{n-1})}$$

- ▶ **Markov-Annahme:** z_n ist unabhängig von $z_1, \dots, z_{n-1}$ wenn wir x kennen.

$$\begin{aligned} P(x | z_1, \dots, z_n) &= \frac{P(z_n | x)P(x | z_1, \dots, z_{n-1})}{P(z_n | z_1, \dots, z_{n-1})} \\ &= \alpha P(z_n | x)P(x | z_1, \dots, z_{n-1}) \\ &= \alpha_n \prod_{i=1 \dots m} P(z_n | x_i)P(x_i | z_{1:n-1}) \end{aligned}$$



- ▶ In den meisten Fällen ist die Welt dynamisch
- ▶ Aktionen des Roboters oder von anderen Agenten
- ▶ Wie können wir solche Aktionen in unser Modell integrieren?
- ▶ Typische Aktionen:
 - ▶ Der Roboter dreht seine Räder
 - ▶ Der Roboter benutzt seinen Manipulator, um ein Objekt zu greifen
 - ▶ Pflanzen wachsen über die Zeit
- ▶ Aktionen haben nicht mit 100% Wahrscheinlichkeit das gewünschte Resultat
- ▶ Im Gegensatz zu Messungen erhöhen Aktionen im Allgemeinen die Unsicherheit
- ▶ Zur Modellierung fügen wir die Aktion u in die aktuelle Zustandsschätzung ein




$$P(x_t \mid u, x_{t-1})$$



Zustandsübergänge

- ▶ $P(x_t | u, x_{t-1})$ für $u = \text{"schlieÙe die Tür"}$



- ▶ Wenn die Tür offen ist, ist die Aktion in 90% aller Fälle erfolgreich
- ▶ Integration über die Ausgänge:

$$P(x_t | u) = \sum P(x | u, x_{t-1})P(x_{t-1})$$

(diskret)

$$P(x_t | u) = \int P(x | u, x_{t-1})P(x_{t-1})dx_{t-1}$$

(kontinuierlich)




Bayes-Filter - Beispiel (3)

► Dritte Aktion: "Tür schließen"

$$\begin{aligned}P(\text{closed} | u) &= \sum P(\text{closed} | u, x')P(x') \\&= P(\text{closed} | u, \text{open})P(\text{open}) \\&\quad + P(\text{closed} | u, \text{closed})P(\text{closed}) \\&= \frac{9}{10} * \frac{5}{8} + \frac{1}{1} * \frac{3}{8} = \frac{15}{16}\end{aligned}$$


$$\begin{aligned}P(\text{open} | u) &= \sum P(\text{open} | u, x')P(x') \\&= P(\text{open} | u, \text{open})P(\text{open}) \\&\quad + P(\text{open} | u, \text{closed})P(\text{closed}) \\&= \frac{1}{10} * \frac{5}{8} + \frac{0}{1} * \frac{3}{8} = \frac{1}{16} \\&= 1 - P(\text{closed} | u)\end{aligned}$$



$$P(\text{open}) = \frac{5}{8}$$



Markov-Annahme



$$p(z_t | x_{0:t}, z_{1:t}, u_{1:t}) = p(z_t | x_t)$$
$$p(x_t | x_{1:t-1}, z_{1:t}, u_{1:t}) = p(x_t | x_{t-1}, u_t)$$



Allg. Bayes-Filter: Modell (1)

- Gesucht: evidenzbasierte Zustandsschätzung

$$\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t+1}) = f(\mathbf{e}_{1:t+1}, \mathbf{P}(\mathbf{X}_t | \mathbf{e}_{1:t}))$$

- Für irgendeine Funktion f und Evidenzen (Aktion oder Messung) e
- Unter der **Markov-Annahme**: Eine Evidenz ist unabhängig von allen anderen, gegeben der aktuelle Zustand

► Ansatz:

$$\begin{aligned}\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t+1}) &= \mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t}, \mathbf{e}_{t+1}) \\ &= \eta \cdot \mathbf{P}(\mathbf{e}_{t+1} | \mathbf{X}_{t+1}, \mathbf{e}_{1:t}) \cdot \mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t}) && \text{[Bayessche Regel]} \\ &= \eta \cdot \mathbf{P}(\mathbf{e}_{t+1} | \mathbf{X}_{t+1}) \cdot \mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t}) && \text{[Markow-Annahme]}\end{aligned}$$

Filterung **Prädiktion**



Allg. Bayes-Filter: Modell (2)

- Vereinfachung der Prädiktion:

$$\mathbf{P}(\mathbf{X}_{t+1}|\mathbf{e}_{1:t}) = \int_{\mathbf{x}_t} [\mathbf{P}(\mathbf{X}_{t+1}|\mathbf{x}_t, \mathbf{e}_{1:t}) \cdot P(\mathbf{x}_t|\mathbf{e}_{1:t})]$$

Aktuelle Wahrscheinlichkeit
für Zustand

$$= \int_{\mathbf{x}_t} [\mathbf{P}(\mathbf{X}_{t+1}|\mathbf{x}_t) \cdot P(\mathbf{x}_t|\mathbf{e}_{1:t})]$$

[Markow-Annahme]

- Zusammengefasst:

$$\mathbf{P}(\mathbf{X}_{t+1}|\mathbf{e}_{1:t+1}) = \eta \cdot \mathbf{P}(\mathbf{e}_{t+1}|\mathbf{X}_{t+1}) \cdot \int_{\mathbf{x}_t} [\mathbf{P}(\mathbf{X}_{t+1}|\mathbf{x}_t) \cdot P(\mathbf{x}_t|\mathbf{e}_{1:t})]$$

- So nicht praktikabel:
 - kontinuierliche Verteilungen, Integration
- Unterschiedliche Vereinfachungen / Approximationen möglich



- Voraussetzung: Roboterhandeln + Umgebungsdynamik wird beschrieben als Folge von abwechselnd Aktion / Ereignis und Zustandsmessung, gegeben Start-Zustandsschätzung

1. Prädiktion:


- Sage resultierenden Zustand für Aktion/Ereignis im aktuellen Zustand voraus (**a-priori-Zustandsschätzung**)
- (z.B. berechne erwartete Zielpose für Fahrbefehl);
- führe die Aktion aus (bzw. das unabhängige Ereignis geschieht)

2. Filterung:

- Miss resultierenden Zustand; ggf. mach mehrere unabhängige Messungen (die sich widersprechen dürfen)
- z.B. miss Pose durch Odometrie und durch IMU;
- berechne aktuelle Zustandsverteilung, die maximal gut zu allen Messungen und der Vorhersage passt (**a-posteriori-Zustandsschätzung**)
- weiter bei 1.



Handeln und Messen



- Erziele Unabhängigkeit durch Abwechseln von Messen-Handeln-Messen-Handeln-...
- **Konvention:** Sortiere Evidenzen in Aktionen u_i , Messungen z_i
- **Konvention:** Wahrscheinlichkeit des Zustands x heißt $Bel(x)$ ("Belief")

$$Bel(x_t) = P(x_{t-1} | u_1, z_1, \dots, u_t, z_t)$$

- Vereinfachung: Diskrete Zustände $\Rightarrow$ Ersetze $\int$ durch $\sum$

$$Bel(x_t) = \eta P(z_t | x_t) \sum_{x_{t-1}} P(x_t | x_{t-1}, u_t) \cdot Bel(x_{t-1})$$

(Statisches) Sensormodell

Aktionsmodell



Algorithmus Bayes-Filter

Eingabe : Aktueller Belief $Bel(x_t)$, sowie ein Paar (u, z) .

Ausgabe: Aktualisierter Belief $Bel(x_{t+1})$

```
1: for alle Zustände  $x_t$  do                                     // Update nach Aktion
2:    $\overline{Bel}(x_{t+1}) = \sum_{x_t} P(x_{t+1} | u, x_t) Bel(x_t)$ 
3: end for
4:  $\eta = 0$ 
5: for alle Zustände  $x_{t+1}$  do                                   // Update nach Messung
6:    $Bel(x_{t+1}) = P(z | x_{t+1}) \overline{Bel}(x_{t+1})$ 
7:    $\eta = \eta + Bel(x_{t+1})$ 
8: end for
9: for alle Zustände  $x_{t+1}$  do                                   // Normierung
10:   $Bel(x_{t+1}) = \eta^{-1} Bel(x_{t+1})$ 
11: end for
12: return  $Bel(x_{t+1})$ 
```

Belief a priori


Belief a posteriori



- ▶ Die Bayes'sche Regel erlaubt es uns Wahrscheinlichkeiten zu berechnen, die sonst nur schwer zu erheben wären
- ▶ Mit Hilfe der Markov-Annahme können rekursive Bayes-Filter benutzt werden, um Evidenzen zu kombinieren
- ▶ Bayes-Filter sind **das** Standardwerkzeug für Zustandsschätzungen in dynamischen Systemen
- ▶ Bayes-Filter werden in vielen Bereichen verwendet
 - Kalman-Filter (siehe gleich)
 - Partikelfilter (siehe Kapitel 5)
 - Hidden Markov Models
 - Dynamic Bayesian Networks
 - Partial Observable Markov Decision Processes (POMDPs)




Wo sind wir?





Kalman-Filter - Die Motivation

- ▶ Einsatz mehrerer Sensoren, deren Messwerte mit Unsicherheiten belegt sind
- ▶ Ziel: Zustandsschätzung basierend auf mehreren unabhängigen Messungen, so dass
 - ▶ ... die Gesamtunsicherheit reduziert wird
 - ▶ ... glaubwürdige Informationen stärker gewichtet werden als unplausible
 - ▶ ... die abgeleitete Lösung statistisch “besser” ist als die Einzellösungen



Modellierung aller Schätzungen durch Gaußfunktionen!




Kalman-Filter als spezieller Bayes-Filter

$$\mathbf{P}(\mathbf{x}_{t+1} \mid \mathbf{x}_t, \mathbf{u}_t) = \mathcal{N}(\mathbf{A}\mathbf{x}_t + \mathbf{B}\mathbf{u}_t, \Sigma_{\mathbf{u}})(\mathbf{x}_{t+1})$$

$$\mathbf{P}(\mathbf{z}_t \mid \mathbf{x}_t) = \mathcal{N}(\mathbf{H}\mathbf{x}_t, \Sigma_{\mathbf{z}})(\mathbf{z}_t)$$

n	Dimension Zustand
m	Dimension Aktion
l	Dimension Messung

- $\mathbb{1}$ Einheitsmatrix ($n \times n$)-dimensional
- $\mathbf{A}$ Transitionsmodell ($n \times n$)-dimensional, modelliert spontane Transitionen. Ist gleich $\mathbb{1}$, wenn keine spontanen Transitionen erfolgen
- $\mathbf{B}$ Aktionsmodell ($n \times m$)-dimensional, konvertiert $\mathbf{u}$ in den Zustandsraum
- $\Sigma_{\mathbf{u}}$ Kovarianzmatrix für Aktionsmodell ($n \times n$)-dimensional
- $\mathbf{H}$ Sensormodell, ($l \times n$)-dimensional. Konvertiert Zustand in den Messraum
- $\Sigma_{\mathbf{z}}$ Kovarianzmatrix für Sensormodell ($l \times l$)-dimensional





1. Prädiktion:

- Sage resultierenden Zustand für Aktion/Ereignis voraus
- Schätze den Fehler nach aktuellem Fehlermodell ab
- Führe die Aktion aus (bzw. unabhängiges Ereignis geschieht)

2. Filterung:

- Miss resultierenden Zustand
- Ggf. mach mehrere unabhängige Messungen (die sich widersprechen dürfen)
- Nimm als aktuellen Zustand den an, der maximal gut zu allen Messungen und dem letzten bekannten Fehlermodell passt
- Aktualisiere Fehlermodell (!)
- Weiter bei 1.



A-priori-Vorhersagen für $t + 1$:

$$\begin{aligned}\underline{x}_{t+1} &:= \mathbf{A}\mu_t + \mathbf{B}u \\ \underline{\Sigma}_{t+1} &:= \mathbf{A}\Sigma_t\mathbf{A}^T + \Sigma_u\end{aligned}$$

← Vorhergesagter Zustand zu $t + 1$ nach u

← Vorhergesagte Kovarianz zu $t + 1$ nach u

Filterung / Korrektur:


$$\begin{aligned}\mu_{t+1} &= \underline{x}_{t+1} + \mathbf{K}_{t+1}(\underline{z} - \mathbf{H}\underline{x}_{t+1}) \\ \Sigma_{t+1} &= (\mathbf{I} - \mathbf{K}_{t+1}\mathbf{H})\underline{\Sigma}_{t+1}\end{aligned}$$

Rote Kurve

grüne Kurve

$\mathbf{K}_{t+1}$ sagt, wie hoch der Vorhersagefehler in neuen Wert eingeht
"Kalman Gewinnmatrix (*Kalman Gain*)":

$$\mathbf{K}_{t+1} = \underline{\Sigma}_{t+1}\mathbf{H}^T(\mathbf{H}\underline{\Sigma}_{t+1}\mathbf{H}^T + \Sigma_z)^{-1}$$





Eingabe : x_t aktueller Zustand, Σ_t aktuelles Fehlermodell, sowie ein Evidenz-Paar (u, z)

Ausgabe: Die aktualisierten x_{t+1}, Σ_{t+1}

1: *Prädiktion mit Hilfe der Aktion u*

2: $\bar{x}_{t+1} = Ax_t + Bu$

3: $\bar{\Sigma}_{t+1} = A\Sigma_t A^T + \Sigma_u$

4: *Korrektur mit Hilfe der Messung z*

5: $K_{t+1} = \bar{\Sigma}_{t+1} H^T (H \bar{\Sigma}_{t+1} H^T + \Sigma_z)^{-1}$

6: $x_{t+1} = \bar{x}_{t+1} + K_{t+1}(z - H\bar{x}_{t+1})$

// Zustand $x_i \hat{=}$ Mittelwert μ_i

7: $\Sigma_{t+1} = (\mathbb{1} - K_{t+1}H) \bar{\Sigma}_{t+1}$

8: **return** x_{t+1}, Σ_{t+1}



- ▶ Gauß / Normalverteilung nicht zwingend für Kalman-Filter:
 - ▶ Systemrauschen mit Mittelwert 0
 - ▶ Fehlerquellen untereinander mit Kovarianz 0
 - ▶ Lineare Transitionen
 - ▶ Lineare Abhängigkeiten zwischen Zuständen und Sensormessungen
- ➔ **Unter diesen Bedingungen ist der Kalman-Filter optimal!**
 - ▶ Kein anderes Verfahren schätzt die Systemzustände mit geringeren erwarteten Abständen zwischen geschätztem und tatsächlichem Zustand
 - ▶ Kalman-Filter nutzt die vorhandenen Informationen optimal aus



Beispiel: Gleichförmige Bewegung + GPS

Erinnerung:

$$\underline{x}_{t+1} := A\mu_t + Bu$$

$$\underline{\Sigma}_{t+1} := A\underline{\Sigma}A^T + \underline{\Sigma}_u$$

$$\mu_{t+1} = \underline{x}_{t+1} + K_{t+1}(z - H\underline{x}_{t+1})$$

$$\underline{\Sigma}_{t+1} = (1 - K_{t+1}H)\underline{\Sigma}_{t+1}$$

$$K_{t+1} = \underline{\Sigma}_{t+1}H^T(H\underline{\Sigma}_{t+1}H^T + \underline{\Sigma}_z)^{-1}$$

Start bei $x_0 = 0$, $\sigma_0 = 0$, $\Sigma_0 = [0]$, sei $u = \Delta x = 3,2$

Sei $\sigma_u = (|\Delta x|)/10 = 0,32$

$$\Rightarrow \Sigma_u = [\sigma_u^2] = [0,32^2]$$

$$\Rightarrow \underline{x}_1 = 3,2$$

$$\Rightarrow \underline{\Sigma}_1 = \Sigma_0 + \Sigma_u = [0,32^2]$$

Weiter gelten $H = [1]$ und $\Sigma_z = [\sigma_z^2] = [0,05^2]$

$$\Rightarrow K_1 = (0,32^2)/(0,32^2 + 0,05^2) = 0,97616$$

$$\Rightarrow \underline{\Sigma}_1 = (1 - K_1)\underline{\Sigma}_1 = [0,00244^2]$$

Sei Messwert $z_1 = 4,75$

$$\Rightarrow \mu_1 = \underline{x}_1 + K_1(z_1 - H\underline{x}_1) = 3,2 + 0,97616(4,75 - 3,2) = 4,71$$

Messung gewinnt, da sie deutlich zuverlässiger ist:

$$\sigma_z \ll \sigma_u$$





Für einen hypothetischen mobilen Roboter bestehe der Zustandsraum aus folgenden Komponenten:

- den Koordinaten x, z
- der Orientierung θ
- dem Luftdruck in Osnabrück λ
- dem Namen des Papstes π

Unabhängig von den Aktionen des Roboters kann sich der Luftdruck von einem zum nächsten Zustand von selbst mit einer Standardabweichung von 0.001 hPa ändern. Die Roboteraktionen ändern weder den Luftdruck, noch den Namen des Papstes. Der Roboter kann die aktuellen Werte von x, z, θ und λ messen.

- (1) Geben Sie die Matrizen **A**, **B** und **H** für die beschriebene Domäne an!
- (2) Modellieren Sie die Aktionen *Rotation* und *Translation* mit gegebenen Standardabweichungen!
- (3) Beispielrechnung von drei Iterationen für gegebene Initialwerte und Aktionen



Beispielaufgabe - Diskussion

- Besprechung Form und Dimension der erforderlichen Matrizen

Lösung: Sei $x = \begin{pmatrix} x \\ z \\ \theta \\ \lambda \\ \pi \end{pmatrix}$ der Zustandsraum, $u = \begin{pmatrix} \Delta x \\ \Delta z \\ \Delta \theta \end{pmatrix}$ der Aktionsraum und $Z = \begin{pmatrix} x \\ z \\ \theta \\ \lambda \end{pmatrix}$ der Messraum