










Ausblick: Roboterkarten in 3D

	3D		
	Sensordaten	syntaktische Merkmale	semantische Merkmale
Metrisch kont.			
Metrisch diskret			
Topologisch	<i>Topologie in 3D prinzipiell denkbar, aber schwierig zu motivieren.</i>		




Topologische Karten in 3D





Topologische Karten in 3D






Continuous Multilayer and Multilevel
Shortest Path Vector Field Navigation
on 3D Triangular Meshes in the Forest

Robotik

Prof. Dr. Thomas Wiemann - FB AI - Robotik



Hochschule Fulda
University of Applied Sciences





Recap Roboterkarten

- ▶ Man braucht Karten für Lokalisation, Pfadplanung, ggf. Anwendungszwecke
- ▶ Möglicherweise mehr als 1 Karte
- ▶ Dient 1 Format mehreren Zwecken, umso besser!
- ▶ Rasterkarten – für Informatiker*innen effizient in Quad/Octrees
- ▶ Oft aber auch als einfache Graustufenbilder (.png)
- ▶ In der Robotik essentiell: automatische Erstellbarkeit (⇒ Kap. 7)
- ▶ Bei hybriden Repräsentationen (mehr als 1 Karte / Darstellung) sind der Übergang und die Synchronisation zwischen Repräsentationen interessant (Forschungsgebiet!)
- ▶ Braucht man eigentlich mehr als 1 Karte, bloß weil der Schulatlas mehrere thematische Darstellungen auf Papier enthält? Merke: Aus 1 GIS erzeuge viele Karten!

Eine Roboterkarte ist eine explizite, persistente Repräsentation des Raums, die der Roboter für seine Steuerung nutzt.

Offene Fragestellung:

Wie erstellen ich allgemeingültige wiederverwendbare semantische Karten von großflächigen Arealen? ⇒ Themen für Abschlussarbeiten massig vorhanden!



Gliederung

Lokalisierung

Lokalisierung in Karten

1. Arten von Roboterkarten
2. Lokalisierung an Landmarken
- 3. Markow-Lokalisierung**
4. Monte-Carlo-Lokalisierung



Formen von Lokalisierung

- ▶ Triviale Lokalisierung
 - keine mobilen Einheiten $\Rightarrow$ kein Lokalisierungsproblem („Lokalisierung“ = momentane interne Pose: z.B. Automationsroboter)
- ▶ Keine Lokalisierung
 - Kenntnis der Pose unnötig/unerwünscht $\Rightarrow$ keine Lokalisierung („verhaltensbasierte“ Robotik, random-walk-Staubsauger)
- ▶ Inkrementelle Lokalisierung (relative L., Lokale L., tracking)
 - Ermittle Pose-Änderung relativ zu Startpose oder zu Zwischenposen
 - Haben wir in mittels EKF gemacht
- ▶ Globale Lokalisierung (Absolute L.)
 - Ermittle Pose in externem Bezugssystem („Karte“, Koordinatensystem)





Erinnerung: Allgemeiner Bayes-Filter

$$\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{e}_{1:t+1}) = \eta \cdot \mathbf{P}(\mathbf{e}_{t+1} | \mathbf{X}_{t+1}) \cdot \int_{\mathbf{x}_t} [\mathbf{P}(\mathbf{X}_{t+1} | \mathbf{x}_t) \cdot P(\mathbf{x}_t | \mathbf{e}_{1:t})]$$

Erinnerung: Spezieller Bayes-Filter (Handeln/Messen)

$$Bel(\mathbf{X}_{t+1}) = \eta \cdot \mathbf{P}(\mathbf{Z}_{t+1} | \mathbf{X}_{t+1}) \sum_{x_t} \mathbf{P}(\mathbf{X}_{t+1} | \mathbf{X}_t, \mathbf{u}_{t+1}) \cdot Bel(\mathbf{X}_t)$$

Sensormodell,
a-posteriori-Pose

Aktionsmodell,
a-priori-Pose

Markow-Lokalisierung ist die (naive) Anwendung des (multimodalen) Bayes-Filters aufs Lokalisierungsproblem



MARKOW DEPT. OF ROBOTICS

- ▶ Interpretiere Pose als Zufallsvariable über $[X, T, \theta]^T$ -Poseraum (beliebig / multimodal verteilt)
- ▶ Aktionen & Messungen bilden Wahrscheinlichkeitsverteilungen auf Wahrscheinlichkeitsverteilungen ab



Spezieller Bayes-Filter (Idee)

- Voraussetzung: Roboterhandeln + Umgebungsdynamik wird beschrieben als Folge von abwechselnd Aktion / Ereignis und Zustandsmessung, gegeben Start-Zustandsschätzung (Poseverteilung)

1. Führe Aktion aus
2. Schätze resultierenden Zustand für Aktion (a-priori.Zustandsmessung)
3.
$$\overline{Bel}(\mathbf{X}_{t+1}) = \sum_{X_t} P(\mathbf{X}_{t+1} | \mathbf{u}_t, \mathbf{X}_t) \cdot Bel(\mathbf{X}_t)$$
4. Miss resultierenden Zustand
5. Filterung: berechne aktuelle Zustandsverteilung, die maximal gut zu allen Messungen und der Vorhersage passt (a-posteriori-Zustandsschätzung). Weiter bei 1.
6.
$$Bel(\mathbf{X}_{t+1}) = \eta P(\mathbf{Z} | \mathbf{X}_{t+1}) \cdot \overline{Bel}(\mathbf{X}_{t+1})$$



Algorithmus Bayes-Filter

Eingabe : Aktueller Belief $Bel(x_t)$, sowie ein Paar (u, z) .

Ausgabe: Aktualisierter Belief $Bel(x_{t+1})$


```
1: for alle Zustände  $x_t$  do                                     // Update nach Aktion
2:    $\overline{Bel}(x_{t+1}) = \sum_{x_t} P(x_{t+1} | u, x_t) Bel(x_t)$ 
3: end for
4:  $\eta = 0$ 
5: for alle Zustände  $x_{t+1}$  do                                   // Update nach Messung
6:    $Bel(x_{t+1}) = P(z | x_{t+1}) \overline{Bel}(x_{t+1})$ 
7:    $\eta = \eta + Bel(x_{t+1})$ 
8: end for
9: for alle Zustände  $x_{t+1}$  do                                   // Normierung
10:   $Bel(x_{t+1}) = \eta^{-1} Bel(x_{t+1})$ 
11: end for
12: return  $Bel(x_{t+1})$ 
```

Belief a priori

Belief a posteriori



1D-Beispiel (Quasikontinuierlich)




(a) Start: Pose
z.B. gleichverteilt

„objektiv wahre“ Pose,
dem Roboter selber unbekannt!



1D-Beispiel (Quasikontinuierlich)




(b) Messung/Filterung:
„vor Briefkasten“






1D-Beispiel (Quasikontinuierlich)





1D-Beispiel (Quasikontinuierlich)





Lokalisierung in Rasterkarten - Ansatz


- ▶ Messe / Schätze die Eigenbewegung unter Berücksichtigung aller zur Verfügung stehenden Informationen (Odometrie, Winkelhistogramme, Gyrodometrie etc.)
- ▶ $\Rightarrow$ A-priori Pose-Schätzung relativ zur letzten Pose
- ▶ Nach einer festen Zeit vermesse die Umgebung mit einem Laserscanner oder einer Kamera
- ▶ Berechne eine a-posteriori Poseschätzung an der die Sensordaten und die a-priori-Schätzung maximal gut mit der Rasterkarte zusammen passen

Optimiere für eine gegebene Rasterkarte den Fit zwischen geschätzter Pose, ausgeführten Bewegungen und Sensormessungen.



Diskretisierung der Poseverteilung

- Geh aus von Raster-Belegungskarte (hier uniformes Raster)
- Jede Rasterzelle liegt in Kopien diskreter Orientierung vor
- Pose ist Wahrscheinlichkeitsverteilung $\mathbf{P}(\mathbf{X}) = \mathbf{Bel}(\mathbf{X}_t = (x, z, \theta))$





Aufgabe 5: Markow-Lokalisierung

2+15+6 = 23 Punkte

Ein mobiler Roboter bewegt sich durch einen kreisförmigen Korridor mit 8 Feldern. Er befindet sich zu Anfang auf Feld 1. Der Roboter kann sich um eine Anzahl an Zellen fortbewegen. Allerdings ist diese Bewegung sehr unsicher. Bewegt er sich um eine Anzahl an Zellen, so gelangt er nur zu 50 % Wahrscheinlichkeit auf dem Zielfeld. Zu jeweils 25 % gelangt er stattdessen auf eines der benachbarten Feldern des Zielfeldes. In einigen Feldern sind Landmarken (Sterne) angebracht, die alle gleich aussehen. Befindet sich der Roboter auf einem Feld mit Landmarke, so wird diese mit einer Wahrscheinlichkeit von $3/4$ erkannt. Befindet sich der Roboter jedoch auf einem Feld ohne Landmarke, so wird diese tatsächlich mit einer Wahrscheinlichkeit von $5/8$ nicht erkannt.

☆ 1	2	3
8		4
☆ 7	6	☆ 5

Der Roboter führt die folgenden Aktionen aus und macht die angegebenen Messungen:

1. Bewegt sich 1 Zelle gegen den Uhrzeigersinn. Erkennt eine Landmarke.
2. Bewegt sich 4 Zellen mit dem Uhrzeigersinn. Erkennt eine Landmarke.



Naive Markow-Lokalisierung ist naiv

- ▶ Umgebungen interessanter Größe ergeben Verteilungen von nicht handhabbarer Größe!
- ▶ (20m x 50m bei 10 cm und 3.6° Auflösung $\Rightarrow 10^8$ Posen!)
- ▶ Auflösung verringern verwäscht die Lokalisierung
- ▶ $\Rightarrow$ So geht es nur für kleine Umgebungen!

Warum soll man eigentlich unsichere Information bis ins letzte Detail präzise durchrechnen?



Gliederung

Lokalisierung



Lokalisierung in Karten

1. Arten von Roboterkarten

2. Lokalisierung an Landmarken

3. Markow-Lokalisierung

4. Monte-Carlo-Lokalisierung



Monte-Carlo-Algorithmen approximieren aufwändige exakte Lösungen durch effizientes Berechnen von (relativ wenigen) Stichproben